

指導教員印

2021年度 学位論文

意味を持った範囲制限をするための活性化
関数を加えた Deformable Convolution

指導教員 荒井 秀一 教授

東京都市大学 知識工学部
情報科学科
知識情報処理研究室
1812035 折田 汐凪

目 次

第1章 序論	1
第2章 背景	2
2.1 Semantic Segmentation	2
2.2 従来研究	3
2.2.1 CNN(Convolutional Neural Network)	3
2.2.2 Bottleneck 構造の CNN	6
2.2.3 HRNet (High-Resolution Network)	6
2.2.4 DHRNet (Deformable High-Resolution Network)	7
2.3 研究目的	7
第3章 提案手法	9
3.1 DHRNet (deformable High-Resolution Network)	9
3.1.1 Basic Block	10
3.1.2 Bottleneck	11
3.1.3 Exchange Unit	12
3.1.4 Up sampling	12
3.1.5 Deformable Basic Block	12
3.2 Deformable Convolution	12
3.2.1 offset	13
3.3 提案手法	14
第4章 実験	15
4.1 実験条件	15
4.1.1 データセット	15
4.1.2 評価指標	15
4.1.3 ハイパーパラメタ	16
4.1.4 実験環境	16
4.2 実験結果及び検討	17
4.2.1 DHRNetV2 の有効性の確認	17
4.2.2 提案手法の有効性の確認	18
第5章 結論	21

参考文献	23
付録 A 基礎事項	26
A.1 活性化関数	26
A.2 Batch Normalization	27
A.3 バイリニア補間	27
A.4 1×1 Convolution(Pointwise Convolution)	27
A.5 誤差逆伝播法(Back-propagation)	27
A.6 損失関数	28

第1章

序論

近年、少子高齢化などの影響により製造業界や物流業界では人手不足に陥っている。人手不足を解消するために、人間が担当していた作業を自動化する取り組みが進んでいる。自動化の例として、ピッキング作業をロボットに行わせる試みがある。ピッキング作業には、様々な物体の位置と形状を正確に認識して物体の掴む場所を決定した後に、実際に掴んで動かすという2つの動作が求められる。しかし、以前までに研究されていた“物体検出”[1][2]はシーン中に存在する物体のクラスと位置を認識し、矩形の枠で囲む技術であった。そのため様々な形状の物体の位置は認識できても、細かい形状は認識できないため、物を実際に掴む、動かすのは困難である。この問題を解決するために“Semantic Segmentation”[3][4]が登場した。Semantic Segmentationは入力画像に対してピクセル単位でクラス分類を行うことで、物体の輪郭で領域分割する技術である。これによりシーン中の物体のクラス、位置のみならず、詳細な形状まで認識することができるため、Semantic Segmentationはロボットビジョンへの応用が期待されている。このような需要があるため、画像認識分野においてSemantic Segmentationに関する研究が盛んに行われている。

第2章

背景

本章では、まず Semantic Segmentation を概説し、Semantic Segmentation においてどのような手法が提案されてきたのかを説明する。最後にこれらの従来手法の問題点を明らかにしたうえで、本論文の研究目的を述べる。

2.1 Semantic Segmentation

Semantic Segmentation は図 2.1 のように入力画像に対してピクセル単位でクラス分類を行うことで、画像中の様々な物体をそれぞれの外形で領域分割する技術である [3][4]。そのため、Semantic Segmentation は画像中に存在する様々な物体が、それぞれどのクラスに属し、どのような形状で、どの位置に存在するのかを表現可能であり、シーン理解のタスクにおいて重要な手法である。近年では、深層学習を用いた手法の提案により、以前よりさらに高精度な推論が可能になった。

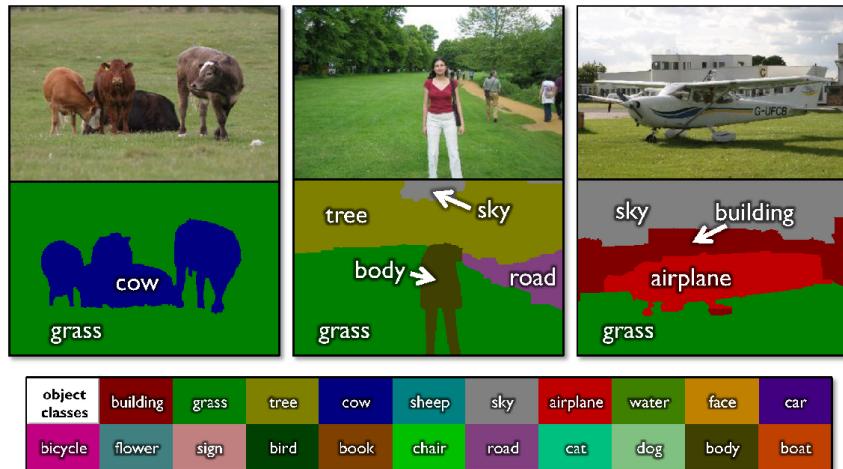


図 2.1: Semantic Segmentation の例 (上段:入力画像、中段:分類結果、下段:クラス凡例)[4]

2.2 従来研究

Semantic Segmentation は深層学習を用いた手法が多く提案されてきた。Semantic Segmentation の多くの手法のもとになっている CNN (Convolutional Neural Network), Semantic Segmentation の手法として多く用いられてきた Bottleneck 構造の CNN, 従来の Bottleneck 構造の CNN より高精度なセグメンテーションを可能にした HRNet (High-Resolution Network), CNN に変更を加えることで HRNet を改良した DHRNet (Deformable High-Resolution Network), これら 4 つの手法を紹介する。

2.2.1 CNN(Convolutional Neural Network)

画像認識では主に CNN[5] が用いられてきた。CNN は深層学習に用いられる多層ニューラルネットワークの 1 つで、畳み込み層, プーリング層, 全結合層で構成されている。ネットワークを多層にすることで、入力に近い層ではエッジなどの特徴を抽出し、深い層になるにつれ、より抽象的な特徴を抽出できるように構成されている。Semantic Segmentation では、CNN の Full Connection 層を Convolution 層に置き換えた、Convolution 層, Pooling 層のみで構成される FCN(Fully Convolutional Network)[6] をベースとしたアーキテクチャが多く提案されている。

Convolution(畳み込み)

Convolution は入力画像に対して学習したフィルタの重みでフィルタリングを行い、その結果を“特徴マップ”として出力する処理である。また Convolution はフィルタの数、フィルタのサイズ、ストライド、パディングの 4 つのパラメタを持ち、それらを設定する必要がある。フィルタの数とは畳み込むカーネルの種類数であり、学習されたフィルタカーネル毎に特徴マップが出力され、その特徴マップの数が Convolution の出力チャンネル数になる。フィルタのサイズは、フィルタカーネルの高さと幅がパラメタである。図 2.2 の場合は高さ 3、幅 3 の 3×3 カーネルである。

Convolution は、入力データと学習した重みを持つフィルタとで畳み込み演算をして、“特徴マップ”を出力する処理である。畳み込み演算は、図 2.2 の灰色で表したフィルタを一定間隔でスライドさせながら、フィルタの要素と入力データの対応する要素を乗算し、その和を求める演算である。また Convolution はフィルタの数、フィルタのサイズ、ストライド、パディングという設定する必要のあるパラメタを持つ。まず、フィルタの数があり、設定したフィルタの数だけ特徴マップを出力する。次にフィルタのサイズはフィルタの幅と高さであり、図 2.2 のカーネルは高さ 3、幅 3 である。

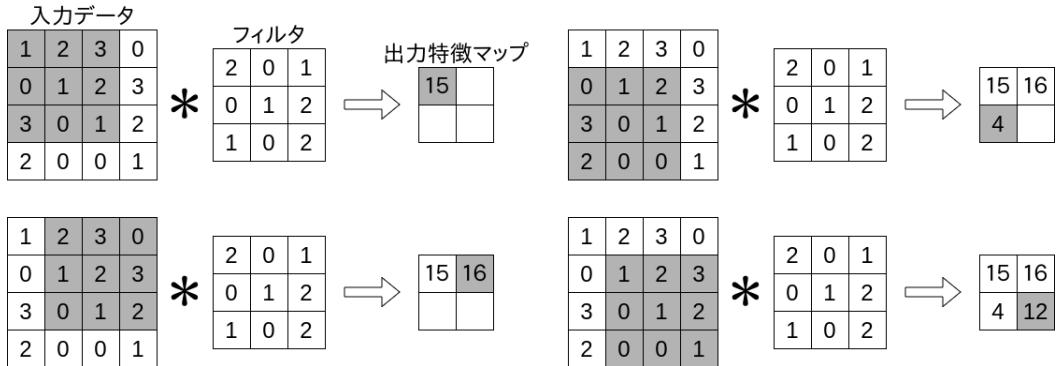


図 2.2: Convolution の例 (*は畳み込み積分)

入力データを $I(x, y)$, 出力特徴マップを $O(x, y)$, フィルタカーネルを $h(m, n)$, フィルタサイズを $(2M + 1) \times (2N + 1)$ とした場合, Convolution は式 (2.1) のように書ける.

$$O(x, y) = \sum_{m=-M}^{M} \sum_{n=-N}^{N} h(m, n) I(x + m, y + n) \quad (2.1)$$

$I(x, y)$ のサイズを (X, Y) とすると, $O(x, y)$ は $(M \leq x < X - M, N \leq y < Y - N)$ の範囲までしか求められず, 出力特徴マップのサイズが小さくなってしまう. これを防ぐためにはパディングという処理を行う. パディングは, 図 2.3 のように入力データの周囲を一定の値で埋める処理である. パディングにより $O(x, y)$ は $(0 \leq x < X, 0 \leq y < Y)$ のように入力データと同じサイズの出力特徴マップを得られるようになる.

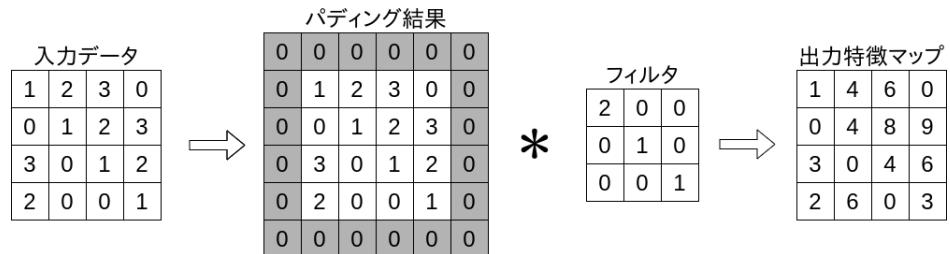


図 2.3: パディングの例

ストライドはフィルタカーネルを移動させる間隔を決めるパラメータである. パディングが入力データと出力特徴マップのサイズを合わせるための処理であるのに対し, ストライドは 1 より大きい整数に変更することで出力特徴マップのサイズを縮小させることができる(図 2.4).

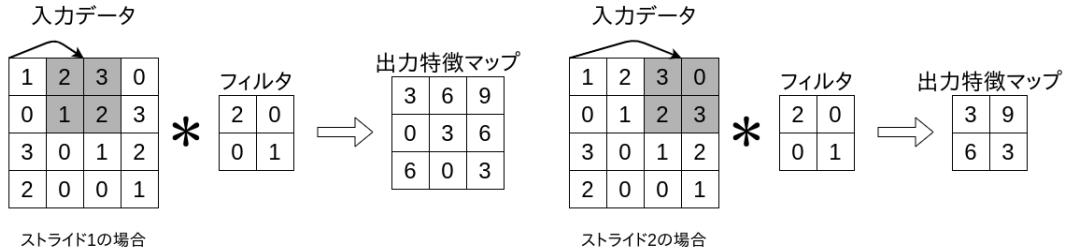


図 2.4: ストライドの例

ストライドを 1 より大きい整数 s に変更した Convolution は式 (2.2) のように書ける.

$$O(x, y) = \sum_{m=-M}^M \sum_{n=-N}^N h(m, n) I(sx + m, sy + n) \quad (2.2)$$

これにより $O(x, y)$ は $(0 \leq x < \frac{X}{s}, 0 \leq y < \frac{Y}{s})$ のように出力特徴マップのサイズが小さくなる. しかし s を大きくしていくと, それに伴い特徴を見落とす可能性が高くなる. 特に s がフィルタカーネルの高さ, または幅を超えてしまうと明らかにフィルタに覆われない領域が出現し, 特徴を見落としてしまう.

Pooling

Pooling は, Convolution により得られた特徴マップのサイズを縮小する処理である. この処理はパラメータの削減や, 受容野を広げる役割があり, また微小な位置ずれに対しロバストになる. 領域内の最大値を得る Max Pooling(図 2.5) や領域内の平均を得る Average Pooling などがある. ストライド 2 の Convolution とストライド 1 の Convolution + 2 × 2 Pooling は出力特徴マップのサイズという面では同じであるが, 後者の方が処理の意味付けが明確にできる.

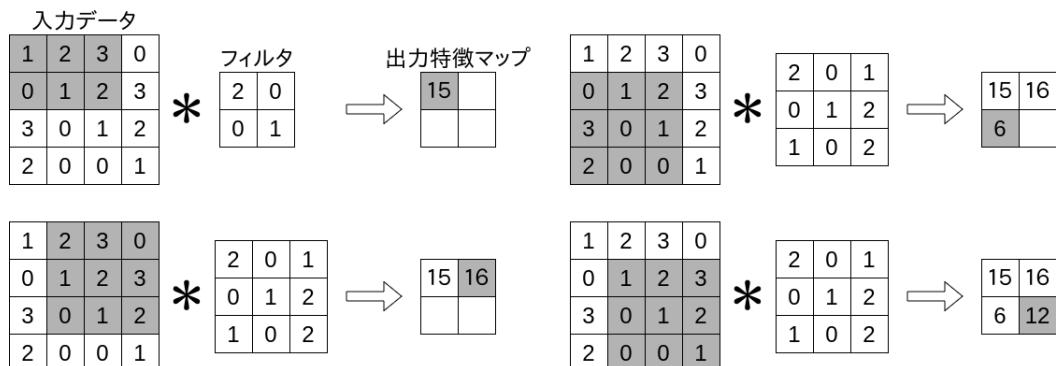


図 2.5: Max Pooling の例

2.2.2 Bottleneck 構造の CNN

Semantic Segmentation の手法として, Bottleneck 構造の CNN(Convolutional Neural Network) が多く用いられている。Bottleneck 構造の CNN は, 入力画像を特徴量抽出しつつ, 解像度を下げていき, 学習可能な層などを用いて入力画像と同等の解像度まで復元する構造をもっている。

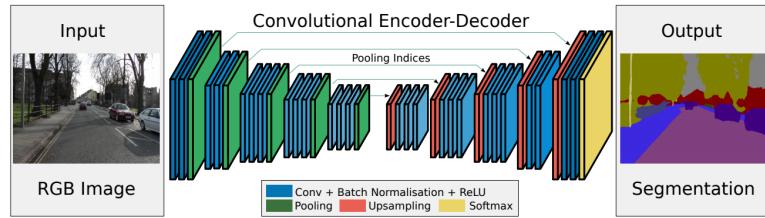


図 2.6: bottleneck 構造の CNN(SegNet[[7]])

bottleneck 構造の CNN の代表的なアーキテクチャは, “SegNet”[7], “U-Net”[8], “RefineNet”[9]などである。これらの手法では, 入力に近い部分で抽出した特徴マップを一旦抽象化してしまうため, 高解像度の特徴マップがもつ物体の詳細な形状の情報が失われてしまう。これは物体の形状を正確に認識する必要がある Semantic Segmentation において大きな問題である。また, 画像を低解像度の特徴量に落とし込んでしまうと, そこから元の解像度に復元することは困難である。

2.2.3 HRNet (High-Resolution Network)

HRNet[10] は, 高解像度と低解像度の特徴マップを直列に扱う従来の手法とは異なり, ネットワーク全体を通して高解像度の特徴マップを維持できる構造を持っている。高解像度の特徴マップのみでは抽象的な特徴は抽出できないため, 層が深くなるごとに低解像度化したネットワークを追加することで, 高解像度から低解像度までの特徴を並列に処理できる構造になっている。この構造により HRNet は, Bottleneck 構造の CNN の構造上の問題である, 物体の細かな形状の情報を維持できない点を改善した。

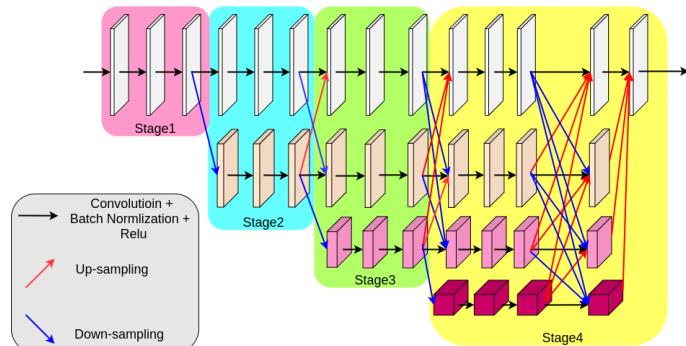


図 2.7: HRNet

2.2.4 DHRNet (Deformable High-Resolution Network)

DHRNet (Deformable High-Resolution Network) は HRNet の低解像度部分にある畳み込み層を受容野が変形可能な Deformable Convolution に置き換えたものである。前節までに Semantic Segmentation のさまざまな手法を紹介してきたが、根本となる Convolution を改善する試みはされていなかった。Convolution は 2.2.1 節で述べたように、入力画像に重みを持った固定サイズのフィルタカーネルをかけ特徴を抽出する処理である。なので、入力特徴マップのうちある出力特徴量に影響を及ぼす範囲である受容野は固定である。しかし、Semantic Segmentation では、様々な形状や大きさの物体の特徴を抽出する必要があるため、固定形状の受容野では特徴抽出に適切ではない。この問題を解決するために、DHRNet は Deformable Convolution という畳み込みを HRNet に適応した。Deformable Convolution は、追加の Convolution で学習した offset ベクトルを用いることで、Convolution の受容野を可変形状にする Convolution である。図 2.8 に受容野を可変にしたフィルタカーネルの例を示す。図 2.8 の赤点が元の畳み込みの受容野、赤線は offset ベクトル、そして青点が offset により移動した後の受容野を表している。DHRNet は都市シーンのセグメンテーションのタスクなどで優秀な成績を収めている。この手法に関する詳しい説明は 3 章で述べる。

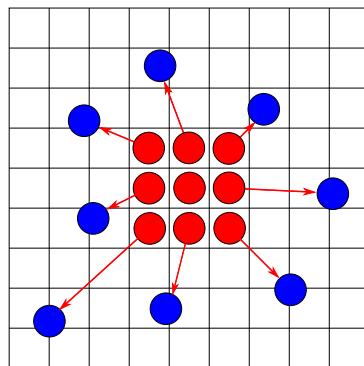
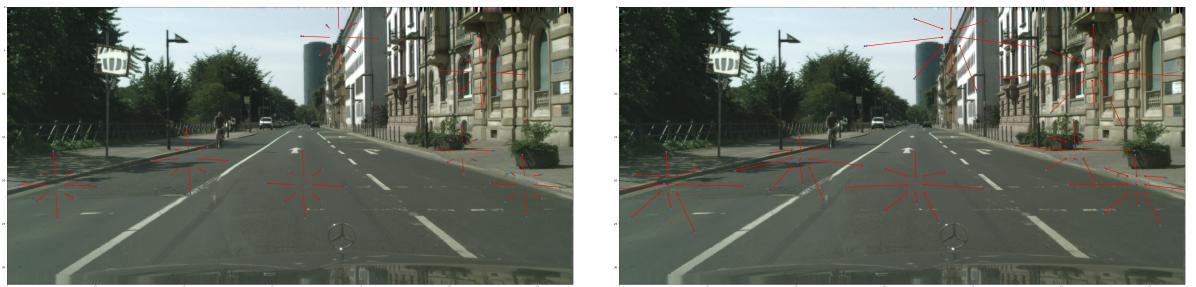


図 2.8: offset による受容野の変化例

2.3 研究目的

2.2.4 節で紹介した DHRNet は、認識精度を向上させることには成功したが、なぜ Deformable Convolution を導入したことで精度が向上したのかは調査されていない。Deformable Convolution は可変受容野により物体の形状に応じた特徴量抽出をすると言わわれている。そこで、deformable convolution により変化したフィルタカーネルの位置を可視化することにより、受容野の変化を視覚的に確認した。

DHRNet には deformable convolution 層が 2 層含まれており、図 2.9a は 1 層目、図 2.9b は 2 層目の可視化結果である。可視化にあたって offset の変化を評価するために 7 つの画素を剪定した。前提として、offset の適切な変化量を定義することは困難であるため、受容野が必ず異なる形状であるべきだと考えた評価点を選定した。評価画素に選んだ点は、道路と歩道とのエッジ付近の点や、物体の中心付近の点である。可視化結果より、以下の 3



(a) 1 層目の deformable convolution の offset (b) 2 層目の deformable convolution の offset
図 2.9: deformable convolution による受容野の変化を可視化

点の結果を示した。

考察 1 エッジ付近と物体の中心付近の受容野の形状には明確な違いが現れると予想した。
しかし可視化結果からは受容野の大きさの変化していることは確認できたが、評価画素ごとに受容野の形状を比較すると、変化は乏しい。

考察 2 convolution は重みを持ったフィルタカーネルと、フィルタカーネルと同じサイズの特徴量とを掛け合わせる処理であるため、出力特徴量が表現できるのは畳み込まれた局所的な特徴の範囲内に制限される。なので畳み込みで算出される deformable convolution の offset ので広がる受容野の大きさには限界があり、限界を超えて移動することが学習の妨げになると考えた。しかし、現状のアーキテクチャは受容野の範囲に制限する構造にはなっていない。それして可視化した需要野の中には収まるべき範囲を超えているものが存在する。

本研究では、deformable convolution の offset の範囲に制限を設けることで、deformable convolution の学習をより促進させることを研究目的とする。

第3章 提案手法

本章では、本研究に使用する HRNet と Deformable Convolution の構造を詳しく説明した後に、offset の範囲に制限を設ける新たな活性化関数を提案する。提案した活性化関数を用いることにより、offset の探索範囲を学習可能な範囲に制限することで学習を促進することを目指す。

3.1 DHRNet (deformable High-Resolution Network)

DHRNet はネットワーク全体を通して高解像度を維持するアーキテクチャである。図 3.1 に示すように HRNet は異なる解像度で処理をするネットワークを組み合わせた 4 つのステージで構成されている。ステージ 1 は入力と同等の解像度で処理するネットワークのみで構成される。続くステージ 2 ではステージ 1 のネットワークに、入力の $1/2$ 倍スケールの低解像度を処理するネットワークを追加する。さらに続くステージ 3 では $1/4$ 倍スケール低解像度を処理するネットワークを追加し、最後のステージ 4 では $1/8$ 倍スケール低解像度を処理するネットワークを追加する。また、ステージ 4 には deformable convolution が適応されている。そして解像度を下げるたびにチャンネル数は 2 倍になる (HRNet V2-w18v1 の場合それぞれ 16, 32, 64, 128 チャンネル)。以降、図 3.1 に示した本アーキテクチャの詳細について説明していく。また、図中の ReLU, Batch Normalization については、それぞれ、付録 A.1, 付録 A.2 で説明する。

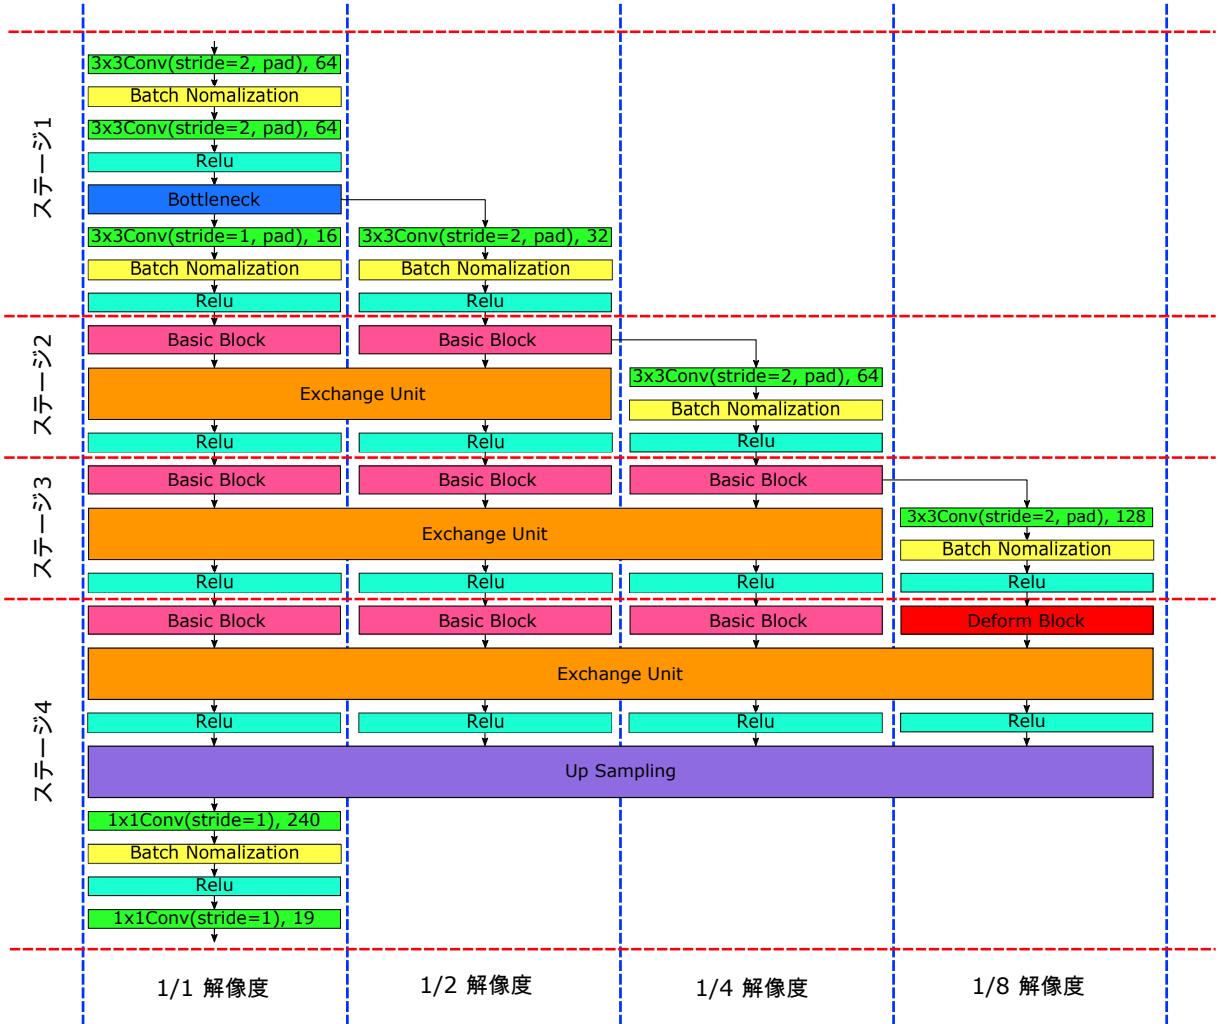
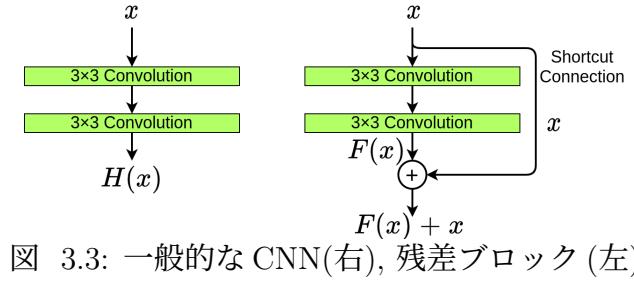
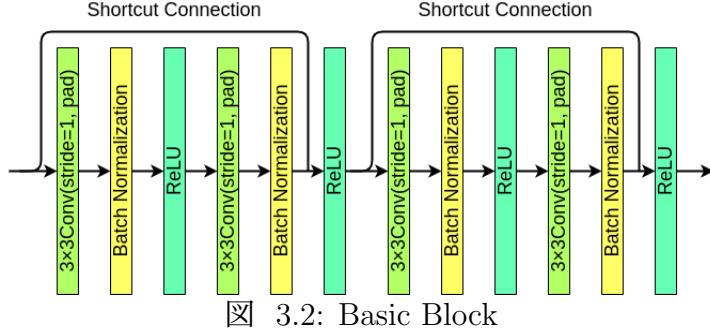


図 3.1: DHRNet の構造

3.1.1 Basic Block

図 3.1 のピンク色で示した “Basic Block” の構造を示したもののが図 3.2 である。このブロックは HRNet において特徴抽出を担う重要な箇所である。一般にこのような構成で層を深くすると、いわゆる “勾配消失” により、ネットワークの重みが更新できなくなる。これを解決する方法はさまざま提案されているが、HRNet V2 では “ResNet(Residual Network)”[11] で提案された “残差ブロック” を用いている。図 3.3 に示すように、一般的な CNN は入力 x を数段の Convolution 層に通して $H(x)$ を得るのに対し、残差ブロックでは、CNN の出力 $F(x)$ と入力 s との和を出力 $H(x) = F(x) + s$ とする。これにより、CNN では $F(x) = H(x) - x$ なる $H(x)$ と入力 s との残差を学習すればよく、残差信号の平均値は 0 に近いので勾配消失を防ぐ効果が期待できる。



3.1.2 Bottleneck

図 3.1 の赤色で示した “Bottleneck” は Basic Block と同様, HRNet V2において特徴抽出を担う箇所で、図 3.4(右)に示すような構造である。構造は残差ブロック(図 3.4(左))に似ているが、Bottleneck では入力のチャンネル数を 1×1 Convolution(付録 A.4)を用いて小さくしてから 3×3 Convolution で特徴抽出し、最後の 1×1 Convolution でチャンネル数を復元する。これにより計算コストを削減できる。例えば、図 3.4において残差ブロックの入力チャンネル 64, Bottleneck が入力チャンネル数 256 と Bottleneck の方がチャンネル数が大きいが、これらの計算コストは同等である。

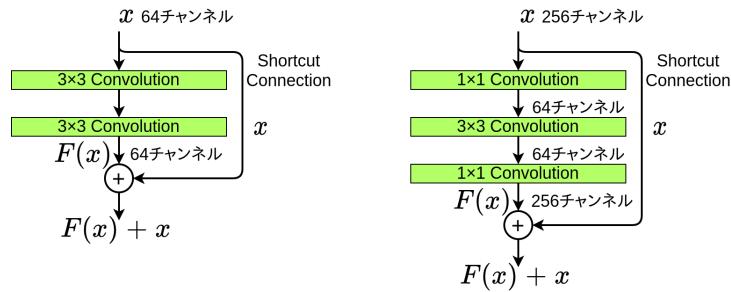


図 3.4: 残差ブロック(右), Bottleneck(左)

3.1.3 Exchange Unit

HRNet V2では異なる解像度の特徴マップ間で情報共有するために“Exchange Unit”がある。図 3.1 ではオレンジ色の部分がそれにあたる。具体的に、Exchange Unit では異なる解像度の特徴マップ間でバイリニア補間によるアップサンプリング、またはストライド 2 の 3×3 Convolution によるダウンサンプリングで特徴マップのサイズを合わせ、特徴マップ同士を加算する。これにより異なる解像度の特徴マップ間で情報共有が可能である。

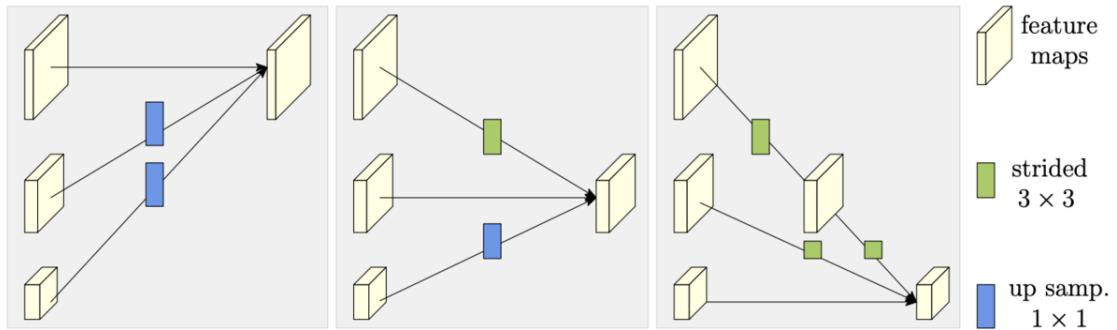


図 3.5: exchange unit[10]

3.1.4 Up sampling

図 3.1 の青色で示した Up sampling は $1/2$, $1/4$, $1/8$ の低解像度の特徴マップをバイリニア補間でアップサンプリングし、それらを $1/1$ 解像度の特徴マップに Concat する。この Up sampling ブロックで得られた特徴マップを分類に用いる。

3.1.5 Deformable Basic Block

図 3.1 の赤色で示した“Deformable Basic Block”的構造を示したもののが図??である。“Deformable Basic Block”は、Basic Block の入力から数えて 1 番目と 3 番目の 3×3 Convolution を deformable convolution に変更した

3.2 Deformable Convolution

Deformable Convolution は Convolution のサンプリング位置からの変位である“offset”を計算、学習をしてフィルタのサンプリング位置を動的に変化させる。そのため画像中の物体のスケール、形状に合わせて受容野のサイズ、形状を変えることが可能である。

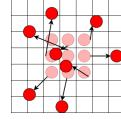


図 3.6: Deformable Convolution

畳み込みのサンプリング位置 p_n の集合を R , w を重み, x を入力特徴マップ, y を出力特徴マップと表したとき Convolution は式 (3.1) のように書ける.

$$R = \{(-1, -1), (-1, 0), \dots, (0, 1), (1, 1)\}$$

$$y(p_0) = \sum_{p_n \in R} w(p_n)x(p_0 + p_n) \quad (3.1)$$

Deformable Convolution では offset Δp を加算する (式 (3.2)).

$$y(p_0) = \sum_{p_n \in R} w(p_n)x(p_0 + p_n + \Delta p_n) \quad (3.2)$$

3.2.1 offset

offset は図 3.7 に示すように, 入力特徴マップに追加の Convolution により求め, 学習する. offset は, x 方向, y 方向の移動量を示す 2 次元ベクトルであるため, offset 算出用の Convolution の出力チャンネル数は $2N$ チャンネルである (N はフィルタカーネルのサイズで, 3×3 フィルタカーネルの場合 $N=9$). また offset は整数であるとは限らないため, offset によって変化した後のサンプリング位置が非整数座標になってしまう場合がある. その場合, 非整数座標に画素値は存在しないため, バイリニア補間で非整数座標の画素値を算出する必要がある (式 (3.3)). (G はバイリニア補間, q は $p_0 + p_n + \Delta p_n$ の周辺の整数座標)

$$x(p_0 + p_n + \Delta p_n) = \sum_q G(q, p_0 + p_n + \Delta p_n)x(q) \quad (3.3)$$

offset Δp_n を学習するために, 式 (3.2), (3.3) のバイリニア補間をもとに勾配を求める式 (3.4) のように求まる. これを用いて, 誤差逆伝播法 (付録 A.5) により学習を行う.

$$\begin{aligned} \frac{\partial y(p_0)}{\partial \Delta p_n} &= \sum_{p_n \in R} w(p_n) \frac{\partial x(p_0 + p_n + \Delta p_n)}{\partial \Delta p_n} \\ &= \sum_{p_n \in R} [w(p_n) \sum_q \frac{\partial G(q, p_0 + p_n + \Delta p_n)}{\partial \Delta p_n} x(q)] \end{aligned} \quad (3.4)$$

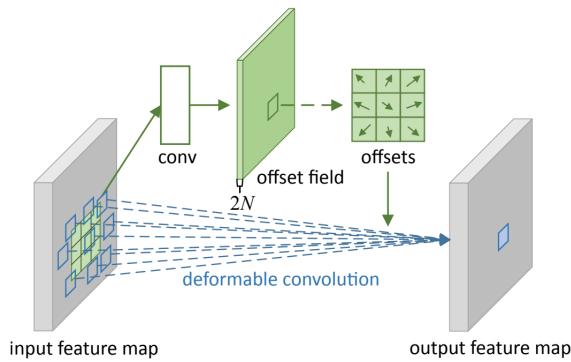


図 3.7: Deformable Convolution の流れ [12]

3.3 提案手法

現状の deformable convolution の構造は, Convolution 層の出力特微量をそのまま offset ベクトルとしており, 特微量が影響を及ぼす範囲外まで offset ベクトルを伸ばすことが可能な構造をしている. そこで本研究では, 算出された offset を存在範囲を制限する hard tanh6(??) を offset に適応することを提案する. 式 (3.5) に示す通り, hard tanh6 は入力値が -6 より小さい場合と 6 より大きい場合は出力値が常に 0 であり, -6 以上, 6 以内の範囲では入力値をそのまま出力する活性化関数である. この提案する活性化関数に offset を通すことによって, offset を中心のサンプリング点が影響を及ぼす範囲内で学習させる. さらに, 現状のアーキテクチャでは中心のサンプリング位置も動いてしまっており, 入力特微量の中でサンプリングされない特徴が出てきてしまう可能性があることに加え convolution の位置普遍性が失われてしまうため, 中心の offset は 0 に固定する.

$$\text{hardtan6}(x) = \begin{cases} 6(x > 6) \\ x(-6 \leq x \leq 6) \\ 0(x < -6) \end{cases} \quad (3.5)$$

第4章

実験

4.1 実験条件

本節では実験条件として、使用するデータセット、評価指標、ハイパーパラメータ、実験環境について述べる。

4.1.1 データセット

本実験では“Cityscapes”[13]を使用した。Cityscapesは都市のストリートシーンの画像で構成されており、学習用画像が2975枚、検証用画像が500枚、テスト用画像が1525枚の計5000枚用意されている。学習の対象とするクラスはroad, sidewalk, building, wall, fence, pole, traffic light, traffic sign, vegetation, terrain, sky, person, rider, car, truck, bus, train, motorcycle, bicycleの19クラスである。

4.1.2 評価指標

学習したモデルの性能を、スレットスコア(Threat Score)を用いた以下の2つの指標で評価する。

- IoU (Intersection over Union)
- MIoU (Mean Intersection over union)

スレットスコアは、正解データと予測結果を2値で比較し、その正誤を表4.1のような4つの状態で表すConfusion Matrixを用いて定義する。

表 4.1: Confusion Matrix

	正解はA	正解はAではない
Aと予測	TP(True Positive)	FP(False Positive)
Aではないと予測	FN(False Negative)	TN(True Negative)

True, False は正しく予測できたかを表し, Positive, Negative は正と負のどちらに予測されたかを表している. Semantic Segmentation において, True Positive は例えば A というクラスを正しく A と判定できたピクセル数, False Positive は別のクラスであるにもかかわらずクラス A と誤った判定したピクセル数, False Negative は A というクラスにもかかわらず別のクラスと誤った判定をしたピクセル数である.

次に, スレットスコアの計算式を示す. そもそもスレットスコアは気象分野で用いられる指標だが, ここで TP, FP をそれぞれ True Positive, False Positive のピクセル数とし, FN を False Negative のピクセル数として, Semantic Segmentation の評価値としてスレットスコアを用いたとき, このスコア値を IoU(Intersection over Union) と呼び, 式 (4.1) のように書ける. IoU はクラスごとに求まるが, これを全体のクラス数 C で平均したものを MIoU(Mean Intersection over Union) と呼び, 式 (4.2) のように書ける.

$$\text{IoU} = \frac{\text{TP}}{\text{TP} + \text{FP} + \text{FN}} \quad (4.1)$$

$$\text{MIoU} = \frac{1}{C} \sum_{c=1}^C \frac{\text{TP}_c}{\text{TP}_c + \text{FP}_c + \text{FN}_c} \quad (4.2)$$

4.1.3 ハイパーパラメタ

従来手法である HRNet[10] と比較するため, 同じハイパーパラメタを使用した. 使用したハイパーパラメタを表 4.2 に示す.

表 4.2: 使用したハイパーパラメタ

Batch Size	12
Epoch	484
活性化関数(中間層)	ReLU
活性化関数(出力層)	SoftMax

4.1.4 実験環境

本研究では以下の環境で実験を行った.

- Python 3.6.12
- Pytorch 1.5
- Tesla V100(32GB)

4.2 実験結果及び検討

本実験の目的の1つが deformable convolution の offset ベクトルの形状を評価することであるため, deformable convolution が2つ含まれている既存の DHNet では妥当な評価ができないと考えた。よって実験では, DHRNet の Deformable Basic Block を図 4.1 に示すような Deformable Convolution が1層のみの “Deformable Basic Block v2” に変更したものをベースにして実験を行う。Deformable Basic Block v2 を導入した DHRNet を “DHRNetV2” とする。

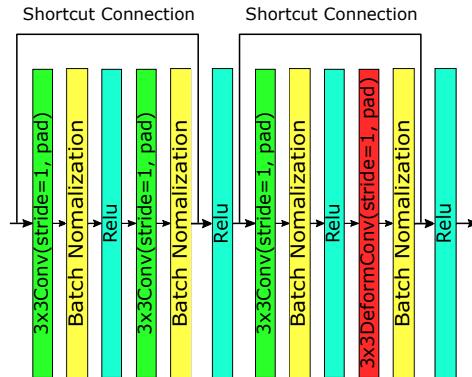


図 4.1: Deformable Basic Block v2

4.2.1 DHRNetV2 の有効性の確認

本研究では, 提案する活性化関数を offset に適応することの妥当性を検討する。そのために, まず DHRNet の有効性を確認する。これを実験1とする。HRNet と DHRNet, DHRNetV2 のクラス全体の結果を表 4.3 に示す。

表 4.3: 実験1の結果(クラス全体)

	MIoU(%)	パラメータ数
HRNet	70.26	1,540,819
DHRNet	74.22	1,918,747
DHRNetV2	73.52	1,729,783

表 4.3 より, DHRNetV2 は DHRNet より 0.7pt 減少したが, HRNet からは 3.26pt 向上した。

次に, 2.3 節で示した (1) 受容野の形状が物体によって変化しているように見えない. (2) 受容野が影響を及ぼす範囲外に伸びている. という問題点が DHRNetV2 にも現れているかを確認するため, offset の可視化と, offset の x 軸成分と y 軸成分をグラフに示す。

可視化結果(図 4.2)の評価画素ごとに受容野の形状を比較すると大きさによる変化は確認できるが, 形状の変化はあまり見られない。次に??と??を見ると, -6 以上 6 以下の範囲外に値が存在する。よって, DHRNetV2 実験に使用するのに適しているといえる。

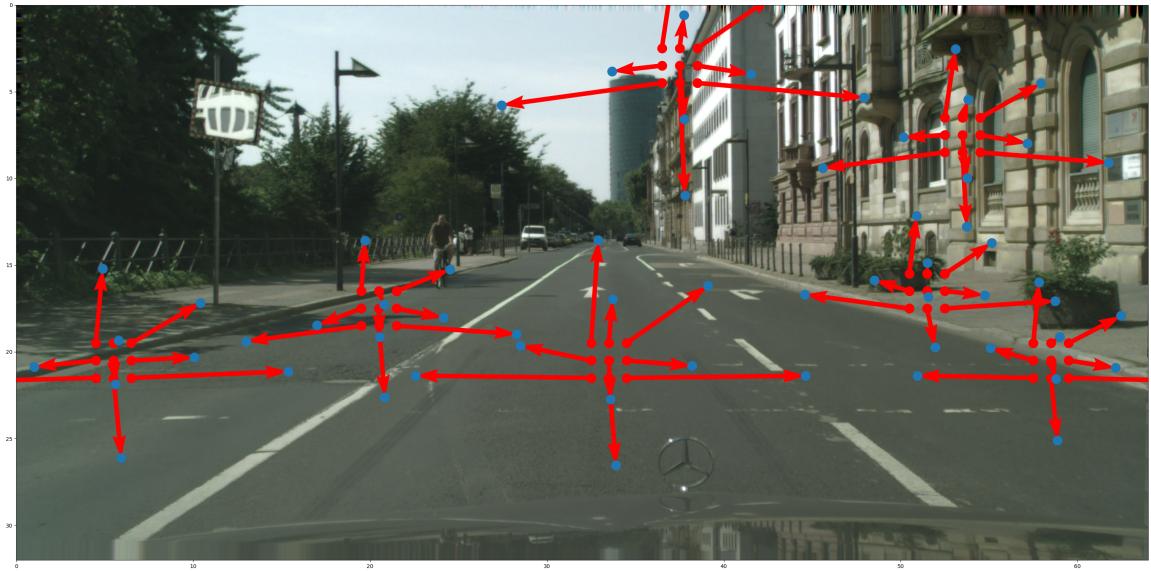


図 4.2: DHRNetV2 の offset の可視化

4.2.2 提案手法の有効性の確認

実験1でDHRNetV2が評価実験のベースとできることを確認した。よって提案する活性化関数の評価を行う、さらにカーネルの中心 offset を固定することで cnn の位置普遍性を担保することの有効性の検証も行う。

DHRNetV2

(提案1) DHRNetV2 に hard tanh6 を導入

(提案2) 提案1に加えて中心の offset ベクトルを 0 に固定

表 4.4: 実験2の結果(クラス全体)

	MIoU(%)	パラメータ数
DHRNet	73.52	1,540,819
提案手法1	73.85	1,540,819
提案手法2	73.28	1,540,819

表 4.5: 実験 2 の結果 (クラスごと)

クラス	IoU(%)			
	HRNet V2	DHRNetV2	提案手法 (hard hanh7)	提案手法 2
road	97.64	97.88	97.89	97.84
sidewalk	82.21	83.00	83.03	82.80
building	90.90	91.62	91.66	91.63
wall	47.10	51.90	50.37	54.53
fence	53.05	55.40	57.56	57.80
pole	60.42	61.67	61.92	61.71
traffic light	63.87	63.17	64.86	64.45
traffic sign	74.33	75.27	75.06	74.82
vegetation	91.89	91.97	92.11	92.08
terrain	62.19	62.52	63.15	62.51
sky	93.74	94.40	94.30	94.26
person	78.58	79.00	79.45	78.83
rider	53.95	57.44	58.11	55.60
car	93.14	93.84	93.64	93.81
truck	50.54	67.19	61.18	65.63
bus	70.68	80.93	79.74	78.34
train	47.08	61.85	67.30	58.55
motorcycle	49.82	54.48	57.57	52.73
bicycle	73.73	73.57	74.20	74.46

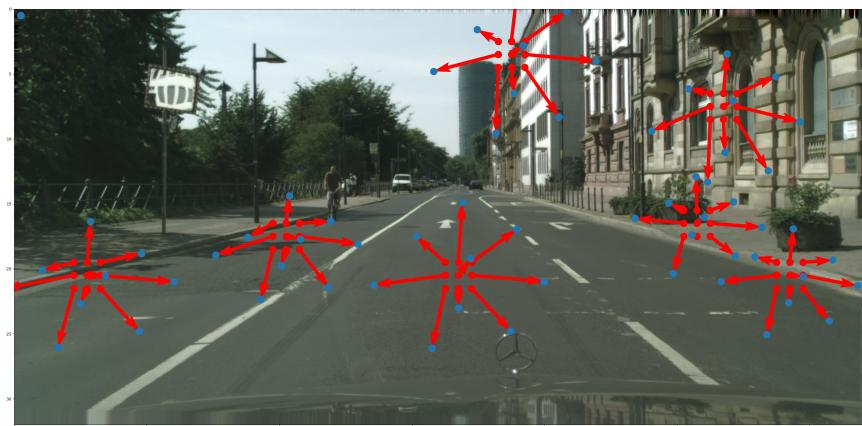


図 4.3: 提案手法 1

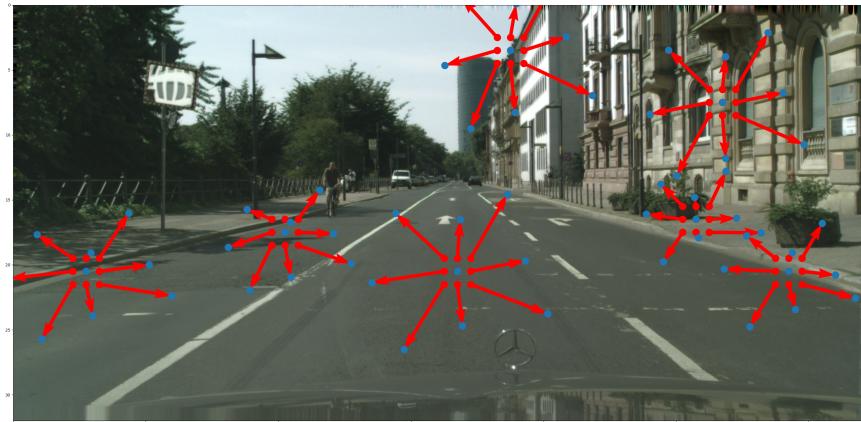


図 4.4: 提案手法 2

第5章

結論

本研究では受容やの大きさや形状が可変な deformable convolution が物体によって受容野の形状をどのように変更しているのかを受容やを可視化することにより視覚的に評価した。その結果、受容野が学習できる範囲外までの広がっていると考えた。そこで受容野の広がる範囲を offset を算出する特徴マップが表現できる範囲内に抑えるために新たな活性化関数を提案した。提案した活性化関数を MIoU, IoU で評価するのに加え、受容野を可視化して意味のある変形をしているかを確認した。結果は、MIoU が 0.3pt 向上し、IoU は多くのクラスにおいて精度の向上をパラメータの追加をせずに達成した。よって deformable convolution の受容野を制限することで学習が促進すると結論付けられる。

謝辞

本論文執筆にあたり、貴重な時間を割き熱心にご指導頂いた荒井秀一教授に心から感謝します。また自らの研究が忙しい中、貴重な時間を割いて助言をして下さった知識情報処理研究室の先輩を始め、1年間苦楽を共にした知識情報処理研究室の皆様に感謝します。

2022年年01月日
折田 汐凪

参考文献

- [1] Ross Girshick, Jeff Donahue, Trevor Darrell, and Jitendra Malik. Rich feature hierarchies for accurate object detection and semantic segmentation. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 580–587, 2014.
- [2] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once: Unified, real-time object detection. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 779–788, 2016.
- [3] Roberto Cipolla Jamie Shotton, Matthew Johnson. Semantic texton forests for image categorization and segmentation. In *Proc. Computer Vision and Pattern Recognition (CVPR 2008)*, pp. 1–8, 2008.
- [4] Jamie Shotton, John Winn, Carsten Rother, and Antonio Criminisi. Textonboost for image understanding: Multi-class object recognition and segmentation by jointly modeling texture, layout, and context. *International Journal of Computer Vision*, pp. 2–23, 2009.
- [5] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. In F. Pereira, C. J. C. Burges, L. Bottou, and K. Q. Weinberger, editors, *Advances in Neural Information Processing Systems*, Vol. 25, pp. 1097–1105. Curran Associates, Inc., 2012.
- [6] Jonathan Long, Evan Shelhamer, and Trevor Darrell. Fully convolutional networks for semantic segmentation. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 3431–3440, 2015.
- [7] Vijay Badrinarayanan, Alex Kendall, and Roberto Cipolla. Segnet: A deep convolutional encoder-decoder architecture for image segmentation. *IEEE transactions on pattern analysis and machine intelligence*, Vol. 39, No. 12, pp. 2481–2495, 2017.
- [8] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *International Conference on Medical image computing and computer-assisted intervention*, pp. 234–241. Springer, 2015.

- [9] Guosheng Lin, Anton Milan, Chunhua Shen, and Ian Reid. Refinenet: Multi-path refinement networks for high-resolution semantic segmentation. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 1925–1934, 2017.
- [10] Jingdong Wang, Ke Sun, Tianheng Cheng, Borui Jiang, Chaorui Deng, Yang Zhao, Dong Liu, Yadong Mu, Mingkui Tan, Xinggang Wang, Wenyu Liu, and Bin Xiao. Deep high-resolution representation learning for visual recognition. *TPAMI*, 2019.
- [11] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 770–778, 2016.
- [12] Jifeng Dai, Haozhi Qi, Yuwen Xiong, Yi Li, Guodong Zhang, Han Hu, and Yichen Wei. Deformable convolutional networks. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, Oct 2017.
- [13] Marius Cordts, Mohamed Omran, Sebastian Ramos, Timo Rehfeld, Markus Enzweiler, Rodrigo Benenson, Uwe Franke, Stefan Roth, and Bernt Schiele. The cityscapes dataset for semantic urban scene understanding. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 3213–3223, 2016.
- [14] Ke Sun, Bin Xiao, Dong Liu, and Jingdong Wang. Deep high-resolution representation learning for human pose estimation. In *CVPR*, 2019.
- [15] Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. p. pp. 37:448–456, 02 2015.
- [16] Yifan Liu, Ke Chen, Chris Liu, Zengchang Qin, Zhenbo Luo, and Jingdong Wang. Structured knowledge distillation for semantic segmentation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 2604–2613, 2019.
- [17] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *2009 IEEE conference on computer vision and pattern recognition*, pp. 248–255. Ieee, 2009.
- [18] Vinod Nair and Geoffrey E Hinton. Rectified linear units improve restricted boltzmann machines. In *ICML*, 2010.
- [19] Geoffrey E Hinton and Russ R Salakhutdinov. Replicated softmax: an undirected topic model. In *Advances in neural information processing systems*, pp. 1607–1614, 2009.

- [20] Daiki Ando and Shuichi Arai. Semantic segmentation using hrnet with deform-conv for feature extraction dependent on object shape. In *2021 3rd International Conference on Cybernetics and Intelligent System (ICORIS)*, pp. 1–5, 2021.

付 錄 A

基礎事項

A.1 活性化関数

活性化関数とは、線形分離できない問題を解くために、ニューラルネットワークの各ユニットからの出力を正規化する非線形な関数である。代表的な関数として Sigmoid 関数や Tanh 関数などがあるが、Semantic Segmentation のネットワークの場合、中間層では “ReLU”[18]、出力層では分類問題で多く用いられる “Softmax”[19] を使用するのが一般的である。以下に本研究で使用する活性化関数について記述する。

Softmax 関数

Softmax 関数 [19] は主に多クラス分類問題での出力層に用いられる。出力層のニューロンの数が n 個あるとして、 k 番目の入力 x_k に対する出力 y_k を求める計算式は、

$$y_k = \frac{\exp(a_i)}{\sum_j^n \exp(a_j)}, \quad (i = 1, \dots, n) \quad (\text{A.1})$$

となる。Softmax 関数の出力は、0 から 1 の間の実数になる。また、Softmax 関数の出力の総和は 1 になる。この性質から Softmax 関数の出力は多クラス問題における確率値として解釈できる。

ReLU(Rectified Linear Unit) 関数

ReLU 関数 [20] は図 3.3 のように、入力値が正ならば値をそのまま出力し、負ならば 0 を出力する関数である。入力を x としたときの式は、

$$h(x) = \begin{cases} x & (x > 0) \\ 0 & (x \leq 0) \end{cases} \quad (\text{A.2})$$

となる。このように ReLU 関数はシンプルであることから、層の数が多くなっても安定した学習ができるため、深層学習の研究において最もよく用いられている活性化関数である。

A.2 Batch Normalization

“Batch Normalization”[15]は、データ全体をいくつかの小さなデータの集合に分割した“ミニバッチ”ごとにデータの分布を平均を0, 分散が1になるように正規化する手法である。この手法により、学習データに過度に適応してしまう“過学習”を抑制することができる。

A.3 バイリニア補間

バイリニア補間は画像の拡大、回転、変形を行うときの画素補間の一種である。求めたい座標の画素値の周囲 2×2 画素値を参照し、その加重平均値を用いて補間する。バイリニア補間の式を式(A.3)に示す。なお f は画素値、 (x_0, y_0) は着目点の座標、 (x, y) は (x_0, y_0) の周囲の格子点座標を表す。

$$\begin{aligned} f(x_0, y_0) = & f(x, y)(1 - \alpha)(1 - \beta) + f(x + 1, y)\alpha(1 - \beta) \\ & + f(x, y + 1)(1 - \alpha)\beta + f(x + 1, y + 1)\alpha\beta \end{aligned} \quad (\text{A.3})$$

$$\begin{aligned} x &= \lfloor x_0 \rfloor \\ y &= \lfloor y_0 \rfloor \\ \alpha &= x - \lfloor x_0 \rfloor \\ \beta &= y - \lfloor y_0 \rfloor \end{aligned}$$

A.4 1×1 Convolution(Pointwise Convolution)

1×1 Convolution(Pointwise Convolution)は、 1×1 カーネルで畳み込み演算を行う。通常のConvolutionは入力特徴マップの空間方向(幅、高さ)とチャンネル方向に同時に畳み込む。対し、 1×1 Convolutionでは、チャンネル方向のみに畳み込む。そのため 1×1 Convolutionはチャンネル数の調整に用いられる。

A.5 誤差逆伝播法(Back-propagation)

ニューラルネットワークは損失関数(付録A.6)が最小になるように学習していくが、その際に損失関数が減少する方向を示す勾配が必要になる。この勾配を効率よく求める方法として誤差逆伝播法がある。誤差逆伝播法は、誤差を出力層から前の層へ次々と伝播していくことで、各層の重みの勾配を求める。

A.6 損失関数

損失関数はネットワークの出力結果と正解データの誤差を表す関数である。出力結果が正解データに近づくほど損失関数から得られる誤差は小さく、出力結果が正解データから離れるほど誤差は大きくなる。ニューラルネットワークでは損失関数が最小になるように学習する。